

量化交易作业 TASK5

AI交易引擎：机器学习算法与场景应用

姓名：薛德刚

分析标的：比亚迪 002594.SZ + 乳腺癌数据集

一、分类型机器学习算法

分类型机器学习是监督学习的一个重要分支，其目标是根据已标注的训练数据学习一个从特征空间到离散类别标签的映射函数，从而对未知样本的类别进行预测。在量化交易领域，分类算法被广泛应用于预测股票涨跌方向、信用违约风险识别、市场状态分类等场景。本任务重点介绍三种经典的分类算法：逻辑回归、决策树和随机森林。

逻辑回归（Logistic Regression）虽然名称中包含“回归”二字，但实际上是一种广泛使用的二分类算法。其核心思想是通过Sigmoid函数将线性回归的输出映射到(0, 1)区间，表示样本属于正类的概率。Sigmoid函数的数学形式为 $\sigma(z) = 1 / (1 + e^{-z})$ ，其中 $z = w^T x + b$ 是特征的线性组合。逻辑回归通过最大似然估计来优化模型参数，使得模型对训练数据的预测概率尽可能接近真实标签。逻辑回归的优点在于模型简单、训练速度快、可解释性强（权重反映特征重要性），且输出的概率值可以直接用于排序和决策。其局限性在于只能处理线性可分的问题，对于复杂的非线性决策边界需要通过特征工程或引入多项式特征来扩展。在量化交易中，逻辑回归常用于构建因子选股模型和风险评估模型。

决策树（Decision Tree）是一种基于树形结构进行决策的非参数分类算法。决策树通过递归地选择最优特征和分裂点，将特征空间划分为若干个互不重叠的区域，每个叶节点对应一个类别标签。决策树的构建过程包括特征选择、决策树生成和剪枝三个步骤。特征选择常用的准则有信息增益（ID3算法）、信息增益比（C4.5算法）和基尼指数（CART算法）。决策树的优点在于：模型直观易懂，可以直接转化为if-then规则；能够处理数值型和类别型特征；不需要特征标准化；能够捕捉特征间的非线性关系和交互效应。其缺点是容易过拟合，特别是当树的深度较大时，模型会对训练数据中的噪声过于敏感。通过限制树的深度（max_depth）或进行剪枝可以缓解过拟合问题。

随机森林（Random Forest）是一种基于决策树的集成学习方法。其核心思想是通过构建多棵决策树并对它们的预测结果进行投票（分类）或平均（回归），来提升模型的泛化能力和稳定性。随机森林在构建每棵树时引入了两层随机性：第一，对训练数据进行Bootstrap采样（有放回抽样），每棵树使用不同的训练子集；第二，在每个节点分裂时，从全部特征中随机选取一个子集作为候选特征，只在子集中选择最优分裂特征。这两层随机性使得各棵树之间具有足够的多样性，从而降低了集成的方差。随机森林的优点包括：预测精度高，通常优于单棵决策树；对过拟合有天然的抵抗能力；能够评估特征重要性；对缺失值和异常值具有较好的鲁棒性；可并行化训练。其缺点是模型可解释性不如单棵决策树，且预测速度较慢（需要多棵树投票）。在量化交易中，随机森林被广泛应用于因子挖掘、多因子选股模型和市场趋势预测等场景。

综上所述，逻辑回归适合处理特征与标签之间关系近似线性的场景，决策树适合需要强可解释性的场景，随机森林适合追求高精度且不需要强解释性的场景。在实际应用中，通常会同时训练多个模型并通过交叉验证选择最优模型。

二、机器学习模型评价指标

机器学习模型的性能评估是模型开发过程中至关重要的一环。选择合适的评价指标不仅能够客观衡量模型的质量，还能指导模型的优化方向。本任务重点介绍混淆矩阵、AUC和ROC曲线三个核心评估概念。

混淆矩阵（Confusion Matrix）是分类模型评估的基础工具，它以矩阵的形式展示了模型预测结果与真实标签之间的对应关系。对于二分类问题，混淆矩阵是一个 2×2 的矩阵，包含四个基本元素：真正例（True Positive, TP）表示实际为正类且预测为正类的样本数；假正例（False Positive, FP）表示实际为负类但预测为正类的样本数；假负例（False Negative, FN）表示实际为正类但预测为负类的样本数；真负例（True Negative, TN）表示实际为负类且预测为负类的样本数。基于混淆矩阵可以衍生出多个评估指标：准确率（Accuracy） $= (TP+TN)/(TP+TN+FP+FN)$ ，衡量整体预测正确率；精确率（Precision） $= TP/(TP+FP)$ ，衡量预测为正类的样本中真正为正类的比例；召回率（Recall） $= TP/(TP+FN)$ ，衡量实际为正类的样本中被正确预测的比例；F1分数 $= 2 \times \text{Precision} \times \text{Recall} / (\text{Precision} + \text{Recall})$ ，是精确率和召回率的调和平均值。在量化交易中，召回率对应“在所有实际上涨的股票中，模型正确预测上涨的比例”，精确率对应“在模型预测上涨的股票中，实际上涨的比例”。

ROC曲线（Receiver Operating Characteristic Curve）是以假正率（FPR=FP/(FP+TN)）为横轴、真正率（TPR=TP/(TP+FN)，即召回率）为纵轴绘制的曲线。ROC曲线通过遍历分类器的所有可能阈值，在每个阈值下计算对应的FPR和TPR，连接所有点形成曲线。ROC曲线直观地展示了模型在不同决策阈值下“召回率”与“误报率”之间的权衡关系。曲线越接近左上角(0, 1)点，表示模型性能越好——即在保持低误报率的同时实现高召回率。对角线 $y=x$ 表示随机分类器的性能，如果ROC曲线低于对角线，说明模型性能不如随机猜测。ROC曲线的优点在于它不依赖于具体的分类阈值，能够全面评估模型在不同工作点下的性能，且对类别不平衡问题不敏感。

AUC（Area Under Curve）是ROC曲线下的面积，取值范围为[0, 1]。AUC将ROC曲线的信息压缩为一个标量值，便于模型间的直接比较。AUC的物理含义是：随机选取一个正类样本和一个负类样本，模型将正类样本的预测概率排在负类样本之前的概率。AUC=1表示完美分类器，AUC=0.5表示随机分类器，AUC<0.5表示模型反向预测（比随机还差）。一般而言，AUC>0.7表示模型具有较好的区分能力，AUC>0.8表示模型性能良好，AUC>0.9表示模型性能优秀。AUC作为评价指标的优点在于：它不依赖于分类阈值的选择，能够综合反映模型的整体排序能力；对类别不平衡数据具有鲁棒性；计算简便且可解释性强。在量化交易中，AUC常用于评估选股模型的排序能力——AUC越高，说明模型对上涨股票和下跌股票的区分能力越强。

在实际应用中，混淆矩阵提供了最基础的分类结果统计，ROC曲线展示了模型在不同阈值下的权衡关系，AUC提供了模型整体性能的量化指标。三者结合使用，可以全面评估分类模型的性能，为模型选择和优化提供依据。

三、模型实现与评估分析

3.1 策略实现

本任务使用scikit-learn库实现三种分类模型的训练与评估。使用两个数据集进行实验：scikit-learn内置的乳腺癌数据集和基于比亚迪日线数据构建的股票收益数据集。核心代码如下：

```

# 1. 加载乳腺癌数据集
from sklearn.datasets import load_breast_cancer
data = load_breast_cancer()
X, y = data.data, data.target  # 30个特征, 0=恶性 1=良性

# 2. 划分训练集与测试集 (70%训练, 30%测试)
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.3, random_state=42, stratify=y)

# 3. 标准化
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

# 4. 构建并训练三个分类模型
models = {
    '逻辑回归': LogisticRegression(max_iter=5000),
    '决策树': DecisionTreeClassifier(max_depth=5),
    '随机森林': RandomForestClassifier(n_estimators=100, max_depth=8),
}
for name, model in models.items():
    model.fit(X_train_scaled, y_train)

# 5. 评估: 混淆矩阵 + AUC + ROC曲线
y_pred = model.predict(X_test_scaled)
y_proba = model.predict_proba(X_test_scaled)[:, 1]
cm = confusion_matrix(y_test, y_pred)
auc = roc_auc_score(y_test, y_proba)
fpr, tpr, _ = roc_curve(y_test, y_proba)

```

3.2 乳腺癌数据集实验结果

乳腺癌数据集包含569个样本、30个特征，按70%/30%划分训练集与测试集。三个模型的ROC曲线对比如图1所示，混淆矩阵对比如图2所示。




图1 乳腺癌数据集 ROC曲线对比（三模型）




图2 乳腺癌数据集 混淆矩阵对比（三模型）

表 1 乳腺癌数据集三模型评估指标对比

模型	准确率	精确率	召回率	F1分数	AUC	TP	FP	TN	FN
逻辑回归	0.9883	0.9907	0.9907	0.9907	0.9981	106	1	63	1
决策树	0.9298	0.9439	0.9439	0.9439	0.9441	101	6	58	6
随机森林	0.9357	0.9444	0.9533	0.9488	0.9915	102	6	58	5

图1、图2和表1解读：

本任务使用scikit-learn内置的乳腺癌数据集（Breast Cancer Dataset）进行分类模型训练与评估。该数据集包含569个样本，30个细胞核形态特征（如半径、纹理、周长、面积、平滑度等），应变量为0（恶性）或1（良性），其中恶性212个、良性357个。数据按70%训练集、30%测试集划分，采用分层抽样保持类别比例。

三个模型的评估结果如下：逻辑回归的准确率为0.9883，AUC为0.9981，混淆矩阵显示仅有1个假正例和1个假负例，分类效果极为优异；决策树的准确率为0.9298，AUC为0.9441，各有6个误分类样本；随机森林的准确率为0.9357，AUC为0.9915，假正例6个、假负例5个。

从AUC指标来看，逻辑回归表现最优（AUC=0.9981），三个模型的AUC均显著高于0.5的随机分类基准，说明它们都能有效区分恶性和良性肿瘤。逻辑回归在乳腺癌数据集上表现最佳的原因在于：该数据集的特征与标签之间主要呈线性关系，且特征经过标准化处理后，逻辑回归的线性决策边界能够很好地拟合数据分布。决策树的AUC相对较低，这是因为单棵决策树容易受到数据中噪声的影响，在有限的训练样本上容易产生过拟合。随机森林通过集成多棵决策树，在AUC上优于单棵决策树，但仍略逊于逻辑回归。

从混淆矩阵来看，三个模型在正类（良性）的识别上均表现出色，召回率均在94%以上，这意味着模型能够有效减少漏诊（将恶性肿瘤误判为良性）的风险，在医学诊断场景中具有极高的实用价值。

3.3 股票收益数据集实验结果

基于比亚迪日线数据构建的股票收益数据集包含223个样本、17个技术指标特征，以次日涨跌方向为应变变量。三个模型的ROC曲线对比如图3所示，混淆矩阵对比如图4所示，随机森林的特征重要性如图5所示。




图3 比亚迪股票收益数据集 ROC曲线对比（三模型）




图4 比亚迪股票收益数据集 混淆矩阵对比（三模型）




图5 随机森林特征重要性（股票收益数据集）

表 2 股票收益数据集三模型评估指标对比

模型	准确率	精确率	召回率	F1分数	AUC	TP	FP	TN	FN
逻辑回归	0.3881	0.2963	0.2667	0.2807	0.4964	8	19	18	22
决策树	0.4179	0.3548	0.3667	0.3607	0.4635	11	20	17	19
随机森林	0.6119	0.5833	0.4667	0.5185	0.6261	14	10	27	16

图3、图4、图5和表2解读：

本任务同时构建了基于比亚迪(002594.SZ)日线数据的股票收益分类数据集。通过计算17个技术指标特征（包括收益率、均线偏离度、波动率、成交量变化、动量指标、RSI等），以次日涨跌方向（1=涨，0=跌）为应变量，构建了一个223个样本的二分类数据集，其中下跌124个、上涨99个。

三个模型在股票数据集上的评估结果如下：逻辑回归的准确率仅为0.3881，AUC为0.4964，接近0.5的随机基准；决策树的准确率为0.4179，AUC为0.4635；随机森林的准确率为0.6119，AUC为0.6261，是三个模型中唯一AUC超过0.6的模型。

与乳腺癌数据集上的优异表现相比，三个模型在股票数据集上的性能大幅下降。这一结果具有重要的实践启示：股票市场的噪声远大于医学诊断数据，短期内（次日）的股价涨跌受大量随机因素影响，技术指标的预测能力有限。逻辑回归和决策树的AUC接近0.5，说明它们几乎无法区分上涨和下跌的样本，这符合有效市场假说的预期——在弱势有效市场中，基于历史价格的技术指标难以获得持续的超额收益。

随机森林在股票数据集上表现相对较好（AUC=0.6261），说明其通过集成多棵决策树能够捕捉到技术指标间的非线性交互关系，提取出部分有价值的预测信号。从特征重要性来看，排名前三的特征为ma5_dev(0.0841)、return_1d(0.0795)、vol_ma5_ratio(0.0716)，这些特征反映了价格动量和成交量变化对次日涨跌的预测能力。

综合两个数据集的实验结果可以得出以下结论：第一，机器学习模型的性能高度依赖于数据本身的信噪比，在信噪比高的医学数据上表现优异，在信噪比低的金融数据上

表现平庸；第二，随机森林通过集成学习能够提升模型的鲁棒性和泛化能力，在复杂数据上优于单一模型；第三，在量化交易中应用机器学习时，不应期望模型能够精准预测短期涨跌方向，而应将模型输出作为概率信号，结合仓位管理和风险控制构建完整的交易系统。