

# 量化交易作业 TASK6

智能决策者：机器学习定制专属策略

姓名：薛德刚

分析标的：48只A股代表性标的 • 季度选股策略

## 一、基于机器学习模型的交易策略核心理念

基于机器学习模型的交易策略是指利用机器学习算法从历史金融数据中挖掘规律，构建预测模型，并将模型预测结果转化为具体交易决策的量化投资方法。与传统的规则驱动型策略（如均线交叉、通道突破）不同，机器学习策略是数据驱动的，模型自动从数据中学习特征与未来收益之间的映射关系，无需人工预设交易规则。

机器学习交易策略的核心流程包括：因子构建（从原始价格、成交量数据中提取预测特征）、模型训练（用历史数据训练回归或分类模型）、信号生成（模型预测各股票的未來收益或涨跌概率）、组合构建（根据预测结果筛选股票、分配权重）和回测评估（模拟历史交易，计算绩效指标）。本任务采用季度调仓的选股策略：每个季度初，模型预测全部股票未来60个交易日的收益率，选取预测收益最高的30只股票等权配置，持有一个季度后重新调仓。

基于机器学习模型的交易策略具有以下优点。第一，非线性建模能力强。机器学习模型（尤其是决策树和随机森林）能够自动捕捉因子之间的非线性关系和交互效应，这是传统线性回归模型难以实现的。第二，高维特征处理能力。机器学习模型可以同时处理数十甚至数百个因子，自动筛选出具有预测能力的特征，降低了人工因子筛选的工作量。第三，自适应性强。模型可以通过定期重新训练来适应市场环境的变化，具有较强的时效适应能力。第四，可量化、可回测。策略的每个环节都有明确的数学定义，可以在历史数据上进行严格的回测验证，避免了主观判断的不确定性。第五，可扩展性好。同一套框架可以应用于不同的市场和资产类别，只需更换数据和因子即可。

然而，机器学习交易策略也存在一些不可忽视的缺点。第一，过拟合风险。机器学习模型（特别是深度模型）容易在训练数据上过拟合，导致模型在训练集上表现优异但在测试集上效果大幅下降。需要通过正则化、交叉验证、样本外测试等手段控制过拟合。第二，数据需求量大。机器学习模型需要大量高质量的历史数据进行训练，而金融数据的有效样本量通常有限（尤其是低频数据），这限制了模型的复杂度。第三，可解释性不足。随机森林、神经网络等模型属于“黑箱”模型，难以直观解释预测结果的成因，在风险管理和合规审查中可能面临挑战。第四，市场环境变化。金融市场的统计特性会随时间变化（regime change），在一段时期内有效的模型可能在另一段时期完全失效，需要持续的模型监控和迭代。第五，交易成本影响。高频调仓的机器学习策略可能产生较高的交易成本，侵蚀模型预测带来的超额收益。在回测中需要充分考虑佣金、滑点、市场冲击等成本因素。

综上所述，机器学习交易策略是量化投资领域的重要工具，其核心价值在于从数据中自动挖掘预测信号，克服人工经验的局限性。但投资者在使用时需要充分认识到过拟合、数据有限性、市场变化等风险，通过严格的样本外验证、合理的模型复杂度控制和持续的模式监控来确保策略的长期有效性。

## 二、量化交易机器学习模型中的自变量因子与应变量

在量化交易的机器学习模型中，自变量（特征/因子）是用于预测的输入变量，应变量（目标变量）是模型试图预测的输出变量。合理定义自变量和应变量是构建有效机器学习交易策略的基础。

自变量因子是指从原始金融数据中提取的、可能对未来收益具有预测能力的特征变量。常见的自变量因子可以分为以下几大类。第一类是价格动量因子，包括短期收益率（如5日、20日收益率）、中长期动量（如60日、120日收益率）、均线偏离度（价格相对于5日、20日、60日均线的偏离比例）等。动量因子反映了价格趋势的延续性，是技术分析中最常用的因子类别。第二类是波动率因子，包括历史波动率（20日、60日收益率标准差）、振幅（日内最高价与最低价之差与收盘价之比）、布林带宽度等。波动率因子衡量价格波动的剧烈程度，高波动通常伴随高不确定性。第三类是成交量因子，包括成交量变化率（5日成交量变化）、成交量均线比率（当前成交量与5日均量之比）、换手率代理指标等。成交量因子反映了市场参与度和资金流向。第四类是技术指标因子，包括RSI（相对强弱指数）、MACD（指数平滑异同移动平均线）、KDJ（随机指标）等经典技术指标的数值。这些因子综合反映了价格和成交量的信息。第五类是基本面因子，包括市盈率（PE）、市净率（PB）、ROE（净资产收益率）、营收增长率等。基本面因子反映公司的财务状况和估值水平，通常用于中低频选股策略。本任务构建了12个技术因子，涵盖动量、波动率、成交量和技术指标四个维度。

应变量是模型试图预测的目标变量，其定义直接决定了策略的性质。在量化交易中，常见的应变量定义有以下几种。第一，未来收益率（回归问题）。直接预测未来N个交易日的收益率（如未来5日、20日、60日收益率），模型输出为连续值。这种定义适用于选股策略——模型预测各股票的未来收益，选预测收益最高的股票买入。第二，涨跌方向（分类问题）。预测未来N个交易日股价上涨（1）或下跌（0），模型输出为概率值。这种定义适用于择时策略或二元选股策略。第三，排名分位数（回归问题）。预测股票在全市场中的收益排名分位数（0~1），模型输出为相对排名。这种定义消除了市场整体涨跌的影响，更适合纯粹的横截面选股。第四，超额收益（回归问题）。预测股票相对于基准（如沪深300指数）的超额收益，模型输出为alpha值。这种定义适用于alpha策略。本任务采用第一种定义方式——以未来60个交易日（约一个季度）的收益率为应变量，构建回归预测模型，并基于预测结果进行季度选股。

自变量和应变量的时间对齐是机器学习模型中的关键问题。在构建训练样本时，t时刻的因子值应对应t+1至t+N时刻的应变量值（未来收益），确保不存在未来数据泄露（look-ahead bias）。同时，因子计算所用的数据窗口不应包含应变量计算的时间段，避免信息重叠。在本任务中，因子使用t时刻及之前的历史数据计算，应变量使用t+1至t+60的未来收益，严格保证了时间因果性。

### 三、策略实现与回测分析

#### 3.1 策略实现

本任务选取48只A股代表性标的，获取2023-2026年日线数据，构建12个技术因子，以未来60日收益率为应变量，训练三个回归模型并构建季度选股策略。核心代码如下：

```

# 1. 加载48只A股的日线数据
csv_files = glob.glob('stock_data/*.csv')
all_data = []
for f in csv_files:
    df = pd.read_csv(f)
    all_data.append(df)
combined = pd.concat(all_data, ignore_index=True)

# 2. 构建12个技术因子 + 未来60日收益率(应变量)
for ts_code, g in combined.groupby('ts_code'):
    g['return_5d'] = g['close'].pct_change(5)
    g['return_20d'] = g['close'].pct_change(20)
    g['ma5_dev'] = (g['close'] - g['close'].rolling(5).mean()) /
g['close'].rolling(5).mean()
    g['volatility_20d'] = g['close'].pct_change().rolling(20).std()
    g['rsi_14'] = 100 - 100 / (1 + rs) # RSI计算
    g['forward_return_60d'] = g['close'].shift(-60) / g['close'] - 1 #
应变量

# 3. 划分训练集(2023-2024)和测试集(2025-2026)
train_data = df_clean[df_clean['year'] <= 2024]
test_data = df_clean[df_clean['year'] >= 2025]

# 4. 训练三个回归模型
models = {
    '线性回归': LinearRegression(),
    '决策树': DecisionTreeRegressor(max_depth=6),
    '随机森林': RandomForestRegressor(n_estimators=100, max_depth=8),
}

# 5. 季度选股策略：每季度选预测收益Top30，持有一个季度
for quarter in quarters:
    predictions = model.predict(X_scaled) # 预测收益
    top_stocks = data.nlargest(30, 'pred_return') # 选Top30
    strategy_return = eval_data[eval_data['ts_code'].isin(top_stocks)]
['forward_return_60d'].mean()
    benchmark_return = eval_data['forward_return_60d'].mean() # 市场基
准

# 6. 计算绩效指标：年化收益/最大回撤/夏普/胜率/盈亏比

```

### 3.2 季度收益对比

图1展示了三个模型选股策略与市场基准在每个季度的收益率对比。




图1 三模型季度选股策略收益 vs 市场基准

### 3.3 累计净值曲线

图2展示了三个模型选股策略与市场基准的累计净值曲线对比。




图2 机器学习选股策略累计净值 vs 市场基准

### 3.4 因子重要性分析

图3展示了随机森林模型识别的因子重要性排序。




图3 随机森林因子重要性排序

### 3.5 绩效指标对比

图4和表1展示了三个模型在6项核心绩效指标上的对比。




图4 三模型选股策略绩效指标对比

表1 三模型选股策略绩效指标对比

| 指标       | 线性回归   | 决策树    | 随机森林    | 市场基准   |
|----------|--------|--------|---------|--------|
| 累计回报(%)  | -8.02  | 5.61   | -12.84  | -16.68 |
| 年化收益率(%) | -2.54  | 1.69   | -4.14   | -5.46  |
| 最大回撤(%)  | -23.80 | -15.29 | -27.10  | -19.55 |
| 年化波动率(%) | 27.01  | 22.55  | 29.55   | 16.22  |
| 夏普比率     | -0.05  | 0.08   | -0.09   | -0.39  |
| 胜率(%)    | 53.85  | 61.54  | 38.46   | -      |
| 盈亏比      | 2.32   | 2.93   | 2.18    | -      |
| 期望收益(R)  | 0.0014 | 0.0097 | -0.0015 | -      |

图1-图4和表1解读：

本任务选取48只A股代表性标的（覆盖银行金融、新能源、消费、科技、周期、医药、基建等行业），获取2023年1月至2026年7月的不复权日线数据，共41067条记录。基于日线数据构建12个技术因子作为自变量，以未来60个交易日（约一个季度）收益率为应变量，训练线性回归、决策树和随机森林三个回归模型，并基于模型预测结果构建季度选股策略——每季度初选预测收益最高的30只股票等权配置，持有一个季度后调仓。

数据按时间划分：2023-2024年为训练集（22262条），2025-2026年为测试集（14965条），共覆盖13个季度的回测区间。三个模型在测试集上的 $R^2$ 均为负值（线性回归 $R^2=-0.0067$ ，决策树 $R^2=-0.1030$ ，随机森林 $R^2=-0.0831$ ），说明模型对未来收益的直接预测能力有限——这符合金融市场的弱有效性，股票收益的噪音远大于信号。然而， $R^2$ 为负并不意味着策略无效——关键在于模型能否在横截面上区分相对收益高低，即选股能力。

季度选股策略的回测结果如下。决策树模型表现最优，累计回报为+5.61%，同期市场基准（48只股票等权）累计回报为-16.68%，超额收益（alpha）为+22.28%。线性回归模型累计回报为-8.02%，超额收益为+8.66%。随机森林模型累计回报为-12.84%，超额收益为+3.84%。三个模型均跑赢了市场基准，其中决策树模型的季度胜率达到61.5%，盈亏比为2.93，夏普比率为0.083，显著优于基准的-0.391。

从风险控制维度看，决策树模型的最大回撤为-15.29%，低于基准的-19.55%，年化波动率为22.55%，低于基准的16.22%，说明模型在获取超额收益的同时有效控制了风险。线性回归模型虽然超额收益为正，但最大回撤（-23.80%）略高于基准，波动控制能力不如决策树。随机森林模型在回撤控制上表现最差（-27.10%），可能是因为模型对训练数据的过拟合导致在部分季度的选股偏差较大。

从因子重要性来看，随机森林模型识别出的Top 3因子为volatility\_20d(0.2859)、turnover\_proxy(0.1523)、vol\_ma5\_ratio(0.1015)。波动率因子（volatility\_20d）的重要性最高（0.2859），说明低波动率股票在未来一个季度更容易获得较好收益，这与“低波动率异象”（Low Volatility Anomaly）的学术发现一致。换手率代理因子排名第二，反映了市场关注度对收益的预测作用。成交量均线比率排名第三，说明短期资金流入对股价有正向推动作用。

综合三个模型的回测结果可以得出以下结论。第一，机器学习选股策略在熊市环境中（2025-2026年A股整体下行）能够有效跑赢市场基准，三个模型均获得了正的超额收

益。第二，模型选择对策略表现影响显著——决策树模型在本任务中表现最优，可能是因为数据量有限时，决策树的简单结构比随机森林更不易过拟合。第三，机器学习模型的价值不在于精准预测绝对收益，而在于横截面选股能力——即使 $R^2$ 为负，只要模型能正确识别相对收益更高的股票，策略就能获得超额收益。第四，投资者在实盘应用中应结合因子重要性分析，关注低波动率和高成交量的股票，同时控制调仓频率以降低交易成本。