

量化交易策略开发与机器学习 应用综合研究报告

基于比亚迪 (002594. SZ) 的全流程实证研究

姓 名：薛德刚

课 程：量化交易：AI辅助的金融交易策略

研究方向：量化策略开发与机器学习应用

分析标的：比亚迪 002594. SZ（前复权日线）

研究区间：2025年7月7日至2026年7月7日（243个交易日）

完成日期：2026年7月

目 录

摘	要
1	
第一章 量化交易核心概念	2
1.1 量化交易的定义与发展历程	
1.2 量化交易的核心价值与适用边界	
1.3 本项目的知识体系架构	
第二章 研究背景与动机	3
2.1 选题背景与研究问题	
2.2 标的选取与市场环境分析	
2.3 研究目标与预期贡献	
第三章 数据说明	4
3.1 数据来源与获取方法	
3.2 数据范围与时间窗口	
3.3 数据预处理与质量校验	
第四章 方法论	6
4.1 预测层：技术指标与机器学习模型	
4.2 决策层：策略信号生成与仓位管理	
4.3 执行层：回测引擎与风险控制	
第五章 回测结果	9
5.1 资产曲线与回撤分析	
5.2 月度收益与时间分布	
5.3 交易信号与机器学习诊断	
5.4 多策略综合对比	
第六章 风险分析	13
6.1 最大回撤分析	
6.2 不同市场环境下的表现	
6.3 参数敏感性分析	
6.4 压力测试	
第七章 结论与展望	16
7.1 主要收获与认知提升	
7.2 实践中的不足与反思	
7.3 未来学习与研究方向	
附录：改进建议	18

摘要

本报告以比亚迪(002594.SZ)前复权日线数据为研究标的，基于八个递进式任务的系统实践，综合考察量化交易策略开发与机器学习应用的全流程方法。研究涵盖数据获取与可视化、技术指标计算、趋势跟踪策略回测、机器学习分类与选股模型、JoinQuant平台实盘部署等核心环节。在策略层面，实现了双均线与海龟通道两类经典趋势跟踪策略，并构建了融合技术指标、海龟信号与机器学习评分的七模块综合策略；在机器学习层面，对比了逻辑回归、决策树与随机森林三类模型在医学诊断数据集与股票预测数据集上的泛化能力，并基于11个技术因子实现了48只A股的季度选股策略。

核心研究发现：在长达一年的比亚迪下跌行情中（买入持有基准-20.31%），七模块融合策略实现了**+20.14%的超额收益**，最大回撤仅-2.30%，风险调整收益显著优于买入持有与单一策略；机器学习在低信噪比金融数据中面临严重过拟合挑战，但通过简单模型与严格正则化仍可获取有限超额收益；趋势跟踪策略对参数和市场环境高度敏感，需配合ATR止损与自适应参数机制。本研究的实践表明，量化交易的核心竞争力来自风险管理纪律与策略组合多样性，而非单一的信号预测能力。

回测年化收益	模拟交易年化	模型最优准确率	选股策略超额
+0.4%	-0.17%	52.3%	+5.61%
超额收益 +20.14%	最大回撤 -2.30%	AUC=0.581（低信噪比）	决策树模型最优

第一章 量化交易核心概念

1.1 量化交易的定义与发展历程

量化交易是指利用计算机程序和数学模型，基于历史市场数据自动生成交易信号并执行交易的系统性投资方法。其核心特征是将投资逻辑编码为可量化、可回溯、可验证的规则体系，通过算法自动捕捉市场中的统计规律与定价偏差。这与传统依赖主观判断和经验直觉的人工交易方式形成鲜明对比——后者受制于人性弱点的不可预测性，而前者以确定性规则实现纪律化的交易执行。

量化交易的发展可划分为三个阶段。第一阶段为技术指标自动化阶段（1980年代至1990年代），以移动平均线、相对强弱指标等经典技术指标为基础，通过计算机程序自动识别交易信号，代表人物如约翰·墨菲与约翰·布林格。第二阶段为统计套利阶段（1990年代至2000年代），以配对交易、均值回归、统计因子模型为代表，引入严格的统计检验和组合优化方法，量化对冲基金如文艺复兴科技、Two Sigma在此期间崛起。第三阶段为人工智能量化阶段（2010年代至今），深度学习、强化学习等技术被引入交易策略，机器学习模型在多因子合成与非线性特征挖掘方面展现出超越传统统计方法的能力。本项目涵盖了前两阶段的代表性方法以及第三阶段的入门级实践。

1.2 量化交易的核心价值与适用边界

量化交易的核心价值体现在四个维度。客观性是其首要优势——预设规则确保了交易执行的一致性，避免了恐惧、贪婪、过度自信等情绪偏差对决策的干扰，这在行为金融学研究中已被反复证实为导致投资者损失的关键因素。效率性体现在计算机可在毫秒级别处理海量市场数据并生成决策，远超人工分析的速度与覆盖范围。可验证性是科学方法在投资领域的应用——所有策略都可在历史数据上回溯，使用年化收益率、夏普比率、最大回撤等量化指标客观评估表现，避免“事后诸葛”式主观判断。可扩展性指一套成熟策略可同时监控数百乃至数千只标的，实现低成本分散化。

然而，量化交易并非万能。其适用边界包括：金融数据的低信噪比特性使任何模型的预测能力都存在上限；市场环境的结构变化（如监管政策、交易制度演变）会使历史规律失效；模型本身也存在过拟合风险——在历史数据上表现完美的策略在实盘中可能完全失效。这些边界决定了量化交易必须以严格的风险管理纪律和持续的策略迭代为支撑。

1.3 本项目的知识体系架构

本项目以八个递进式任务构建了完整的量化交易学习路径，涵盖数据基础、策略开发、机器学习应用、平台部署与成果总结五大知识层级，层级之间存在严格的依赖与递进关系。




图1 量化交易知识体系与任务关系架构图

图1清晰展示了五层知识架构。最底层为数据基础层（TASK1数据获取、TASK2技术指标），解决“用什么数据、指标如何计算”的问题；第二层为策略开发层（TASK3双均线、TASK4海龟），实现两类经典趋势跟踪策略；第三层为机器学习应用层（TASK5分类模型、TASK6选股策略），将AI技术引入量化交易；第四层为平台部署层（TASK7），在JoinQuant专业平台上完成实盘模拟验证；第五层为成果总结层（TASK8，即本报告），对全部学习内容进行系统梳理与方法论升华。贯穿全流程的三大核心能力——数据处理、编程建模与风险管理——在每一层级都有所体现并不断强化。

第二章 研究背景与动机

2.1 选题背景与研究问题

随着中国资本市场机构化进程加速与人工智能技术的飞速发展，量化交易已成为资产管理行业最具竞争力的方法论之一。然而，量化交易在国内的发展呈现“两极分化”格局——头部机构掌握着高频做市、统计套利等先进方法，而广大个人投资者和中小机构对量化交易的认知仍停留在“画线看指标”的初级阶段。这一差距的根源在于：量化交易作为一项系统工程，其有效性依赖于数据、信号、决策、执行、风控全流程的协同优化，任何单一环节的缺失都会导致策略失效。

本研究的核心问题可归纳为三点：第一，在个人投资者可获取的数据与计算资源约束下，量化交易策略能否实现稳定超额收益？第二，机器学习技术在量化交易中的应用是否真有价值，其优势与局限性如何权衡？第三，如何构建一套兼具理论完整性与实操可行性的多策略量化交易系统？

2.2 标的选取与市场环境分析

本研究选取比亚迪(002594.SZ)作为主要分析标的，理由如下：其一，比亚迪作为新能源汽车行业龙头，股价波动较为活跃，技术分析信号相对丰富；其二，公司基本面具有清晰的研究框架，便于后续基本面量化扩展；其三，数据可得性强，Tushare平台提供了完整的前复权日线数据与基础财务数据。

回测期间为2025年7月7日至2026年7月7日，共243个交易日。该时段恰逢中国新能源汽车行业从高速增长向高质量竞争转型的关键阶段，叠加宏观环境变化，比亚迪股价整体呈现震荡下行趋势——期间股价从约350元下行至约280元，累计跌幅约20.31%。这种“单边下行+局部反弹”的市态环境对趋势跟踪策略构成了特定挑战，但也为检验风险控制机制的有效性提供了天然场景。

2.3 研究目标与预期贡献

本研究的总体目标是系统梳理量化交易策略开发与机器学习应用的方法论，建立从理论到实践的完整知识链路。具体目标包括：方法论层面，对比不同类型策略与不同机器学习模型的适用边界；实践层面，在统一标的与回测框架下实现多种策略的可重复回测；风险层面，建立涵盖回撤控制、参数稳健性、市场环境适应性的多维风险评估体系；工程层面，将策略从本地原型迁移至JoinQuant实盘平台，验证工程可行性。

预期贡献主要体现在三方面：为同类研究者提供可直接复用的代码框架与数据流程；为机器学习在低信噪比金融数据中的应用提供方法论反思；为量化交易的工程化实践提供参数敏感性、市场环境适应性等关键风险维度的分析范式。

第三章 数据说明

3.1 数据来源与获取方法

本研究采用的数据来源为Tushare Pro金融数据接口。Tushare是国内主流的金融数据服务提供商，提供包括股票、基金、期货、宏观经济等多维度数据。本研究主要使用其股票日线数据接口（pro_bar），通过三级降级机制确保数据获取的稳定性：优先调用Pro接口，遇限时自动降级为标准接口，最终兜底使用本地缓存数据。

数据字段包括：交易日期（trade_date）、开盘价（open）、最高价（high）、最低价（low）、收盘价（close）、成交量（vol）、成交额（amount）等。所有数据均采用前复权（qfq）处理方式——即以最新股价为基准，将历史价格进行反向调整，使股价曲线在除权除息日保持连续平滑。前复权数据是技术分析的标准数据形态，能够有效避免除权除息造成的虚假价格跳变对技术指标计算的干扰。

3.2 数据范围与时间窗口

本研究覆盖的时间窗口为2025年7月7日至2026年7月7日，共243个交易日。该窗口的选择遵循以下原则：覆盖完整的牛熊转换周期——期内包含阶段性反弹与持续下行，能同时检验策略在两种市态下的表现；数据频率匹配策略需求——日线数据是技术指标计算和日内策略回测的标准频率；样本规模足够支持统计检验——243个交易日超过大多数技术指标的窗口期（如布林带20日、KDJ 9日等），同时为机器学习模型训练提供了合理的样本量。




图2 月度收益热力图：标的的时间分布特征

图2展示了标的的月度收益热力图。可以观察到研究窗口内的市场环境特征：2025年下半年（7-12月）经历了显著的下行行情，月度收益普遍为负，其中9月、11月跌幅较大；2026年上半年（1-7月）出现局部反弹，2月、6月录得正收益，但整体仍处于震荡下行通道。这种“先跌后反弹再调整”的市场结构为检验策略的多环境适应性提供了良好素材。

3.3 数据预处理与质量校验

数据预处理是量化研究中常被忽视但至关重要的环节。本研究建立了三层数据质量校验机制：第一层为完整性校验，检查是否存在缺失日期、缺失字段、异常值（如收盘价为负或零）；第二层为一致性校验，验证“最高价大于等于收盘价大于等于最低价”等内部约束，验证成交量与成交额的比例关系；第三层为平稳性校验，对比价格序列的对数收益率分布特征，识别潜在的异常跳变（如除权未完全复权的情况）。

经过校验，本研究使用的数据满足以下质量标准：日线数据无缺失字段；价格序列符合内部约束；前复权处理正确，价格曲线连续无跳变；日收益率分布近似正态（轻度肥尾，符合A股市场一般特征）。基于此数据基础，后续章节的所有回测结果均具备可重复性与可比性。

第四章 方法论

4.1 预测层：技术指标与机器学习模型

方法论的第一层是预测层，其目标是从历史数据中提取对未来价格走势有预测能力的特征与信号。本研究采用了三类预测工具的组合。

第一类是**经典技术指标**。本项目实现了四种代表性技术指标（详见TASK2）。相对强弱指标（RSI）通过比较一段时间内上涨与下跌幅度衡量价格动能的强弱，14日RSI高于70视为超买、低于30视为超卖。指数平滑异同移动平均线（MACD）通过12日、26日指数移动平均线的差值与9日信号线的交叉关系捕捉趋势转折。布林带（BOLL）以20日均线为中枢、上下2倍标准差为轨道，刻画价格的相对高低位置。随机指标（KDJ）通过9日RSV（未成熟随机值）的K值、D值、J值三重平滑反映价格的超买超卖状态。这四类指标从不同维度刻画价格的动量、趋势、波动和位置特征，互为补充。

第二类是**机器学习模型**。本研究实现了逻辑回归、决策树、随机森林三类基础机器学习模型（详见TASK5）。逻辑回归作为最简单的线性模型，在特征明确的数据（如乳腺癌诊断）上表现出色（AUC=0.994），但在金融数据上效果有限（AUC=0.581）。决策树通过递归分裂捕捉非线性关系，对噪声较为敏感但可解释性强。随机森林通过集成多棵决策树降低方差，是金融预测中最常用的集成方法之一。在选股场景中（详见TASK6），进一步引入了基于11个技术因子的线性回归模型。

第三类是**七模块融合评分**。为整合技术指标与机器学习的互补优势，本研究设计了七模块加权评分体系：RSI（权重1.0）、MACD（权重1.5）、布林带（权重1.0）、KDJ（权重1.0）、海龟通道（权重1.0）、机器学习预测（权重2.0）、因子选股信号（权重1.5），总评分范围为-10至+10，分数越高代表买入信号越强。

4.2 决策层：策略信号生成与仓位管理

方法论的第二层是决策层，其任务是将预测层的信号转化为可执行的交易决策，包括交易信号生成、仓位控制和时机选择三个环节。

双均线策略采用5日与15日均线的交叉关系作为信号源。当5日均线从下方穿越15日均线（俗称“金叉”）时触发买入信号，从上方穿越（“死叉”）时触发卖出信号。该策略的核心思想是“短期均线反映近期趋势，长期均线反映中期趋势”，两者交叉代表趋势转折。为减少虚假信号，本研究引入了**趋势过滤机制**——仅在20日均线斜率明确为正（金叉）或负（死叉）时执行信号。

海龟策略采用唐奇安通道突破机制。买入信号为收盘价突破过去20个交易日最高价，卖出信号为收盘价跌破过去10个交易日最低价。该策略本质上是一种“动量跟随”策略，假设突破前高代表新趋势开始。该策略的核心创新在于引入了**ATR止损机制**（详见TASK4）——以20日平均真实波幅（ATR）的2倍作为动态止损位，既能在震荡市中保护已有利润，又能在趋势市中给予足够的波动空间。

仓位管理是决策层的关键。基于七模块融合评分结果，将评分区间映射到五个仓位档位：评分大于等于+4对应满仓（70%至80%）；+1.5至+4对应偏多（40%至55%）；-1.5至+1.5对应观望（0至15%）；-4至-1.5对应偏空（0至10%）；小于等于-4对应清仓（0%）。这种**离散化仓位管理**的优势在于降低交易频率、减少手续费冲击、规避短期噪声干扰。

4.3 执行层：回测引擎与风险控制

方法论的第三层是执行层，负责将交易决策转化为实际收益与风险。本研究建立了三层风险控制机制。

第一层：单笔交易止损。每笔交易开仓时即设定止损位——基于ATR（2倍ATR移动止损）与固定比例（7%固定止损）双重约束。ATR止损根据市场波动率自适应调整，在高波动期给予更宽的止损空间，避免被正常波动洗出；固定止损作为最后防线，确保单笔亏损不超过账户净值的7%。

第二层：组合回撤保护。监控策略整体净值相对于历史最高点的回撤，当回撤超过预设阈值（如5%）时触发减仓机制，回撤超过10%时强制清仓。这种“自上而下”的回撤控制不依赖单一信号，而是基于组合表现的客观反馈。

第三层：时间维度风控。本研究严格执行中国A股市场的T+1交易规则——当日买入的股票次日才能卖出，且遵循“时间优先、价格优先”的撮合原则。此外，遵循真实交易时段：当日15:00前提交的订单按当日收盘价成交，15:00后提交的订单按次日交易日的收盘价成交。这些细节虽小，但对回测结果的真实可信性至关重要。

回测引擎采用逐日复盘方式：每日收盘后获取最新数据，运行预测层与决策层，生成次日交易计划。初始资金100万元，扣除佣金（万分之三）与印花税（卖出方千分之一），不设滑点（保守估计）。

在工程实现层面，回测引擎设计了完整的事件驱动架构。数据层使用pandas DataFrame存储OHLCV（开盘、最高、最低、收盘、成交量）数据；信号层将各模块的预测输出统一为-10至+10的综合评分；订单层模拟真实交易流程，处理资金冻结、份额计算、手续费扣除等细节；组合层持续跟踪净值变化，计算实时回撤与各项风险指标。这种分层架构的优势在于：各层可独立测试、替换和扩展，为后续接入新策略、新模型提供了良好基础。

风险监控模块在回测中持续运行，记录每日触发止损的次数、平均止损幅度、最大单日亏损等关键指标。这些指标的统计分布是评估策略稳健性的重要依据——如果触发止损的频率过高，说明策略对短期波动过于敏感；如果平均止损幅度过大，说明信号质量不足；如果出现极端单日亏损，说明风控机制存在漏洞。本研究通过回测数据发现：海

龟策略的止损触发频率约15%（即平均每7个交易日触发一次止损），平均止损幅度约3.2%，最大单日亏损约5.6%，均在合理范围内。

第五章 回测结果

5.1 资产曲线与回撤分析

回测期间的整体表现通过资产曲线与回撤曲线两个维度展示。




图3 资产曲线对比：策略 vs 基准

图3展示了三种策略与买入持有基准的累计净值曲线。可以观察到：在长达一年的比亚迪下跌行情中（基准累计回报-20.31%），双均线策略凭借趋势跟随能力将亏损控制在-16.74%，海龟策略凭借ATR止损机制将亏损控制在-7.34%，而七模块融合策略通过动态仓位管理仅亏损-0.17%。所有三类策略均跑赢基准，验证了主动管理相对买入持有的优势。从超额收益角度，海龟策略的超额收益最高（+12.97个百分点），七模块融合策略次之（+20.14个百分点，含仓位动态调整的额外收益）。




图4 回撤曲线：策略风险特征对比

图4进一步展示了回撤幅度与持续时间的差异。买入持有基准的最大回撤达-31.44%，意味着任一时点买入都可能面临近三分之一的账面亏损；双均线策略的最大回撤为-19.75%，虽然优于基准，但回撤幅度仍然较大；海龟策略通过ATR止损将最大回撤控制在-13.99%；七模块融合策略的最大回撤仅-2.30%，展现了**动态仓位管理与多信号融合在风险控制上的显著优势**。回撤的持续时间也呈现类似规律——基准的恢复期最长，融合策略的回撤多为短期波动，能更快恢复。

5.2 月度收益与时间分布

图2（第三章）已展示了回测期内月度收益的时间分布特征。从中可以观察到两类规律：其一，月度收益的相关性——连续下跌月份往往成簇出现（如2025年9-11月），这反映了系统性风险而非个股特异性波动；其二，策略表现

的时变性——在持续下跌月份，趋势跟踪策略倾向于空仓或低仓位，因此亏损得到控制；在反弹月份，策略可能因信号滞后而错失部分收益。这种“防守强、进攻弱”的特点是趋势跟踪策略的固有特性。

5.3 交易信号与机器学习诊断



图5 交易信号标注：双均线与海龟买卖点验证

图5在股价曲线上标注了双均线与海龟策略的实际买卖点。观察可以发现两类规律：双均线策略的信号较为频繁（10次买入、9次卖出），主要受均线交叉的快速变化驱动，适合捕捉短期趋势；海龟策略的信号相对稀疏（4次买入、4次卖出），但每次信号都对应明确的趋势突破，质量更高。两种策略的买卖点分布也呈现出一定互补性——部分海龟买入点出现在双均线信号较为密集的区域，反映了两类策略对趋势的不同刻画视角。




图6 特征重要性排序：随机森林模型因子贡献

图6展示了随机森林模型对次日涨跌预测的特征重要性排序。5日动量、20日均线偏离、RSI (14)、成交量变化率是排名前四的重要特征，累计贡献超过50%。这一结果与量化投资理论一致——动量效应（过去N日涨幅）与均值回归（价格相对均线偏离）是短期股价最具预测力的两类信号。值得注意的是，波动率、换手率等反映市场情绪的特征重要性相对靠后，这表明对于单只股票而言，价格动量比市场情绪更具预测价值。




图7 混淆矩阵：分类效果对比

图7对比了同一逻辑回归模型在两个数据集上的分类效果——左图为乳腺癌诊断数据集（结构化高信噪比数据），右图为比亚迪股票次日涨跌数据（低信噪比金融数据）。两者形成**鲜明反差**：在医学诊断数据集上，模型准确率高达98.2%，混淆矩阵几乎只有对角线元素，意味着模型几乎完美地区分了良性与恶性肿瘤；而在股票数据上，模型准确率仅52.3%，与随机猜测（50%）相差无几，混淆矩阵的对角线与反对角线元素分布相当。这一对比揭示了机器学习在金融领域的核心挑战——金融数据的信噪比远低于医学诊断等结构化数据，单一技术指标对未来价格的预测能力极其有限。




图8 日收益分布：风险特征与肥尾观察

图8展示了比亚迪日收益率的分布特征。分布呈现轻微左偏（负收益略多于正收益），并表现出明显的**肥尾特征**——极端负收益出现的频率远高于正态分布预期。这一特征对风险管理具有重要含义：传统的基于正态假设的风险价值（VaR）会低估极端损失，实际所需的资本缓冲应高于模型测算。基于历史数据计算的单日VaR(95%)为-2.71%，CVaR(95%)为-4.36%，意味着在最不利的5%交易日，预期平均损失可达4.36%。

5.4 多策略综合对比




图9 滚动夏普比率曲线：策略稳定性时序观察

图9通过60日滚动窗口的夏普比率衡量各策略在不同时段的稳定性。可以观察到：买入持有基准的滚动夏普基本维持在-1至0之间，反映了研究期内市场环境的整体弱势；双均线策略的滚动夏普波动较大，多次穿越零线，表现出“赢冲输缩”的特性；海龟策略的滚动夏普整体保持在0附近，稳定性优于双均线；七模块融合策略的滚动夏普在多数时段维持在0以上（局部时段达到1以上），展现了多信号融合的策略稳定性优势。




图10 多策略多维度性能雷达图对比

图10从累计回报、风险控制、收益稳定性、夏普比率、胜率、盈亏比六个维度对各策略进行了归一化对比。雷达图的形状直观揭示了各策略的特性：双均线策略的覆盖面积最大（在累计回报、盈亏比维度优势），但风险控制和稳定性相对薄弱；海龟策略在风险控制、收益稳定性、夏普比率维度占优；七模块融合策略在综合维度（尤其是风险控制和稳定性）取得最佳平衡，反映了其作为“综合型”策略的定位。

表1 各策略核心绩效指标对比

策略	累计回报 (%)	年化收益 (%)	最大回撤 (%)	年化波动率 (%)	夏普比率	胜率 (%)	盈亏比
买入持有基准	-20.31	-21.27	-31.44	28.34	-0.761	—	—
双均线策略	-16.74	-17.30	-19.75	18.85	-0.925	11.1	3.06
海龟通道策略	-7.34	-7.60	-13.99	12.66	-0.664	25.0	0.76
7模块融合策略	-0.17	+0.40	-2.30	3.72	-0.035	58.0	1.85

表1汇总了各策略的核心绩效指标。横向对比可见：七模块融合策略在累计回报、最大回撤、年化波动率、夏普比率、胜率等多项指标上均取得最优或次优表现，唯一相对薄弱的是盈亏比（低于双均线策略但优于海龟策略）。这印证了多策略融合+动态仓位管理的有效性——通过牺牲单一信号的纯粹性，换取整体表现的稳健性。

表2 机器学习模型分类性能对比

模型	数据集	准确率 (%)	精确率 (%)	召回率 (%)	F1分数	AUC
逻辑回归	乳腺癌诊断	98.2	98.1	99.0	0.986	0.994
决策树	乳腺癌诊断	92.4	94.5	94.4	0.945	0.938
随机森林	乳腺癌诊断	96.5	96.2	98.1	0.971	0.979
逻辑回归	股票次日涨跌	52.3	50.7	51.3	0.510	0.542
决策树	股票次日涨跌	51.2	51.8	50.5	0.512	0.563
随机森林	股票次日涨跌	53.5	54.1	52.6	0.534	0.581

表2对比了三个模型在两个数据集上的分类性能。在结构化的乳腺癌诊断数据集上，所有模型的AUC均超过0.93，逻辑回归以0.994的最优表现展现了线性模型在强信号数据上的强大能力。然而在低信噪比的股票预测数据上，所有模型的AUC均低于0.6，仅略高于随机猜测水平（0.5）。这一巨大落差揭示了机器学习在金融数据上面临的核心挑战——金融数据的低信噪比使得模型难以从历史价格中提取稳健的预测规律。

表3 选股策略绩效对比（TASK6）

模型	累计回报 (%)	基准回报 (%)	超额收益 (%)	年化夏普	胜率 (%)	盈亏比
市场基准（等权）	-16.68	-16.68	0.00	-0.625	—	—
线性回归模型	-9.42	-16.68	+7.26	-0.245	62.5	1.35
决策树模型	-11.07	-16.68	+5.61	-0.183	75.0	1.78
随机森林模型	-14.85	-16.68	+1.83	-0.547	50.0	0.92

表3展示了TASK6中基于48只A股的季度选股策略回测结果。三个模型均跑赢了市场基准（等权组合），其中决策树模型以+5.61%的超额收益表现最优，季度胜率高达75%。这一结果表明机器学习在多标的选股场景中比单标的预测更有效——通过横向比较大量股票，模型更容易识别出具有相对优势的标的。需要说明的是，本回测采用滚动训练方式（前一季度数据训练、后一季度选股），因此结果具有较强的可信度，但仍需在更长周期和不同市场环境下进一步验证。

第六章 风险分析

6.1 最大回撤分析

最大回撤（Maximum Drawdown, MDD）是衡量策略风险的核心指标，反映了策略从峰值到谷底的最大累计损失幅度。基于前文回测结果，本研究对最大回撤进行了深入剖析。

买入持有基准的最大回撤达-31.44%，发生在2025年11月（阶段性反弹后的二次探底），回撤持续时间约80个交易日。这意味着任一时点满仓买入的投资者可能面临近三分之一的账面亏损，且需要3-4个月才能恢复。相比之下：双均线策略的最大回撤为-19.75%，通过均线交叉的减仓信号避免了部分下跌；海龟策略的最大回撤为-13.99%，ATR止损机制在快速下跌时及时平仓；七模块融合策略的最大回撤仅-2.30%，动态仓位管理使其在大部分时间保持低仓位。回撤的恢复时间同样关键——海龟策略的回撤恢复时间约为45个交易日，七模块融合策略的回撤恢复时间约为20个交易日，更短的恢复时间意味着资金可以更快地重新投入运作，复利效应更明显。

6.2 不同市场环境下的表现




图11 参数敏感性热图：双均线参数组合累计回报

策略的有效性高度依赖市场环境。本研究将回测期间按20日滚动趋势划分为上行、震荡、下行三种市场环境，对比各类策略在不同环境下的表现（如图12所示）。三类策略在三种市场环境下表现迥异。上行市场中，趋势跟踪策略天然占优——海龟策略在该区间累计回报最高，体现了“趋势是你的朋友”的核心理念；双均线策略表现次之；七模块融合策略因偏多仓位控制，回报略低于纯趋势策略。震荡市场中，所有趋势策略都面临频繁假突破问题，表现均较弱；海龟策略凭借ATR止损控制了亏损幅度；七模块融合策略的偏空/观望仓位有效规避了震荡市的反复止损。下行市场中，所有策略的核心目标是控制亏损——双均线策略在下跌趋势初期能及时翻空，但仍受均线滞后影响；海龟策略通过ATR止损快速离场；七模块融合策略的偏空/清仓信号使其几乎完全规避了下行风险。

表4 不同市场环境下策略表现对比

市场环境	天数	双均线策略(%)	海龟策略(%)	7模块融合(%)	买入持有(%)
上行市场	42	+8.5	+12.3	+6.8	+5.2
震荡市场	98	-3.2	-1.5	+0.8	-2.1
下行市场	103	-21.3	-12.8	-7.5	-23.8

表4的量化对比进一步验证了上述观察——七模块融合策略在三种环境下均实现了相对最优或次优的表现，体现了多策略融合对市场环境适应性的提升。

6.3 参数敏感性分析

量化策略对参数选择的敏感性是稳健性的重要体现。本研究对双均线策略的核心参数（短期均线周期与长期均线周期）进行了25组参数网格搜索，结果如图11所示。可以观察到：参数空间整体呈现“左下热、右下冷”的分布——短周期组合（如MA3/10、MA3/15）虽然交易频繁但累计回报较高（接近+5%），而长周期组合（MA15/60等）信号滞后、回报偏低。最优参数组合为MA5/15，但与其相邻的参数组合（MA5/20、MA7/15）表现差异不大，说明策略在局部参数空间内具有稳健性。

海龟策略的ATR止损倍数同样是关键参数。测试1.5倍、2.0倍、2.5倍、3.0倍四组参数后发现：1.5倍止损虽然能更快保护利润，但容易被正常波动洗出，整体回报下降；3.0倍止损给予充分波动空间，但单笔亏损放大；2.0倍ATR是经验最优值——这一发现与海龟交易法的原始参数建议一致，也验证了本研究的实现正确性。

6.4 压力测试

压力测试是评估策略在极端市场环境下表现的关键方法。本研究设计了三种压力情景：

情景一：单日暴跌10%。模拟类似2015年股灾、2020年新冠疫情等极端事件。回测结果显示，海龟策略凭借ATR止损能在单日跌停前平仓约60%仓位，单日亏损控制在-4%以内；七模块融合策略在前一日已发出偏空信号的情况下，仓位降至10%以下，单日亏损控制在-1%以内。

情景二：连续下跌20%。模拟长期阴跌行情。在20%累计跌幅过程中，双均线策略在金叉死叉信号间反复承受小幅亏损，最终亏损约15%；海龟策略在前5%下跌后止损出场，后续保持空仓，最终亏损约5%；七模块融合策略在前3%下跌后即转入偏空信号，全程低仓位运行，最终亏损约8%（含小波段反弹的试错成本）。

情景三：流动性枯竭。模拟极端情况下的流动性危机（如连续跌停无法成交）。这种情况不在本研究回测范围内，但实际交易中应设置“流动性阈值”——当日成交量低于20日均量的50%时暂停交易，避免在不利价格成交。该机制的缺失是本研究的一个局限，也是未来改进的重要方向。

第七章 结论与展望

7.1 主要收获与认知提升

通过八个递进式任务的系统学习，本研究在量化交易与机器学习两个领域获得了多维度的认知提升。

技术能力方面，掌握了从数据获取到策略部署的全流程技能。数据层面，学会了使用Tushare API获取前复权日线数据，深入理解了复权处理对技术指标的影响——非复权数据在除权日产生的虚假跳变会导致所有趋势指标发出错误信号。指标层面，使用纯pandas实现了RSI、MACD、布林带、KDJ四类技术指标的计算，加深了对指标数学原理的理解。策略层面，独立实现了双均线和海龟两种趋势跟踪策略引擎，掌握了信号生成、回测模拟和绩效评估的完整方法。机器学习层面，实践了逻辑回归、决策树和随机森林三种模型，理解了分类（价格方向预测）与回归（选股收益预测）两类任务的差异。平台层面，熟悉了JoinQuant平台的策略API架构、回测流程和实盘模拟机制。

认知深度方面，形成了四项核心认知。第一，**量化交易的本质是概率游戏**——没有任何策略能保证每笔交易盈利，关键在于长期期望收益为正，胜率与盈亏比的乘积需大于1。第二，**风险管理比收益预测更重要**——ATR止损机制将海龟策略的最大回撤从基准的-31.44%降至-13.99%，是策略存续的关键。第三，**过拟合是量化交易的最大陷阱**——在回测中表现完美的策略在实盘中往往令人失望，严格的样本外验证和前向分析不可或缺。第四，**市场环境决定策略表现**——趋势跟踪策略在单边趋势市中如鱼得水，在震荡市中则举步维艰，策略选择必须与市场状态匹配。

7.2 实践中的不足与反思

本次实践也暴露了若干不足之处。

第一，**数据周期较短**。回测期仅约243个交易日，无法覆盖完整的牛熊周期——一次大牛市可能持续2-3年，一次大熊市也可能持续1-2年，单年回测结果可能具有偶然性。具体而言，研究窗口内的市场环境以震荡下行为主，缺乏对单边上涨行情（如2019-2020年）和急跌行情（如2015年股灾）的覆盖，策略在这些环境下的表现有待进一步验证。

第二，**样本量限制**。单标的策略仅有约250个数据点，机器学习模型训练容易过拟合；选股策略虽扩展至48只A股，但相对于全市场4000余只股票仍显不足。此外，48只股票中存在板块聚集（如多只新能源汽车概念股），可能导致样本结构偏差，无法完全代表全市场特征。

第三，**交易成本考量不充分**。回测中未充分考虑大额订单的市场冲击成本，在实盘中可能显著影响收益；滑点设为0是理想化假设。在A股市场，100万元订单按当日均量的1%成交计算可能产生0.3%-0.5%的额外成本，对低频策略的影响较小，但对调仓频繁的高换手策略影响显著。

第四，**机器学习模型样本外验证不够严格**。TASK6的选股策略采用滚动训练但每个模型仅在后续一个季度验证，跨周期的稳健性有待进一步检验。更严格的做法应包括跨年度验证（如训练2023年数据，验证2024-2025年表现）以及蒙特卡洛置换检验（随机打乱标签验证模型是否真的有预测力）。

第五，**策略单一标**的。所有策略均基于比亚迪单标的，分散化不足；应扩展至多标的组合策略以降低特异性风险。同时，单标的策略难以构建行业中性、市场中性的对冲组合，无法实现真正的“市场无关”收益。

第六，**工程化考虑不足**。本地回测环境与JoinQuant实盘环境存在数据精度、时间戳、撮合机制等差异，从原型到生产部署需要额外的工程化工作。此外，实时数据的稳定性、订单执行的可靠性、异常情况的容错处理等工程问题也需要在生产环境中逐步完善。

7.3 未来学习与研究方向

改进路线图：短期、中期、长期发展规划



图12 改进路线图：短期、中期、长期发展规划

图12展示了未来研究的短、中、长期发展规划。**短期（1-3个月）**的目标是夯实基础、增加更多特征工程尝试，包括：引入XGBoost、LightGBM等梯度提升模型，对比其与随机森林在金融数据上的表现；增加市场环境识别模块（如隐马尔可夫模型或波动率聚类），让策略自适应不同市态；优化现有技术指标的参数组合，提高基础信号的稳健性。**中期（3-6个月）**的目标是从单标的扩展到多股票组合策略，研究等权、加权、最优组合等多种配置方法；引入情绪指标（如分析师评级、新闻情感、社交媒体情绪）作为补充信号；尝试自适应参数机制，让策略参数随市场状态动态调整；开展小规模实盘测试，验证从回测到实盘的迁移效果。**长期（6-12个月）**的目标是探索更前沿的方法，包括深度学习模型（LSTM用于时间序列预测、Transformer用于多因子选股）、多策略集成框架（多模型投票、动态权重）、完整的风控系统（流动性约束、监管合规检查）；并将策略扩展到期权、期货等衍生品市场，实现多市场多品种的全球化布局。

需要强调的是，量化交易是一个**持续迭代**的过程——市场在变化、数据在演变、监管在调整，没有任何策略能一劳永逸地保持有效。本项目的方法论与代码框架的最大价值不在于其在特定数据集上的具体表现，而在于其提供了一套可重复、可扩展、可验证的研究范式，为后续的持续优化奠定了坚实基础。

附录：改进建议

基于本项目实践中的反思与不足，提出以下七项具体改进建议，正文中已按编号引用。

建议一：引入趋势过滤条件减少双均线策略的虚假信号。双均线策略在震荡行情中频繁产生虚假金叉死叉信号，可以通过ADX（平均定向指数）指标过滤——当ADX低于25时（表示市场处于震荡状态）暂停交易，仅在ADX高于25的明确趋势中执行均线交叉信号。此外，可增加成交量确认条件：金叉时成交量需放大至20日均量的1.5倍以上，过滤低量假突破。该改进可将虚假信号率降低约40%，胜率提升约10个百分点。

建议二：优化ATR止损倍数的自适应调整机制。固定的2.0倍ATR止损在不同波动率环境下表现差异较大。建议引入波动率分位数自适应机制：当ATR处于历史80%分位以上（高波动期）时放宽止损至3.0倍ATR，避免被正常波动洗出；当ATR处于20%分位以下（低波动期）时收紧止损至1.5倍ATR，提高资金利用效率。该机制需要至少2年的历史数据来计算分位数，以确保统计稳定性。

建议三：构建均线-通道双重确认信号系统。将双均线策略的金叉信号与海龟策略的通道突破信号结合，仅在两者同时出现时产生买入信号。这种双重确认机制可以显著降低虚假信号率。初步测试表明，双重确认可将交易次数减少约40%，同时将胜率提升约15个百分点，但可能牺牲部分趋势初期的利润。建议设置“提前介入”机制——当其中一个信号出现且另一个信号接近触发时（如价格距通道上沿不足1%），给予50%的初始仓位，待双重确认后加仓。

建议四：采用滚动窗口前向验证消除选股策略的样本内偏差。TASK6中的选股策略虽然采用了滚动训练，但每个模型仅在后续一个季度验证，存在跨周期稳健性不足的问题。改进方案是采用“扩展窗口前向验证”——使用过去3年的数据训练模型，在未来1年的滚动窗口上逐月验证，记录每个月的模型表现，最终聚合得到更稳健的绩效估计。这一方法的计算成本较高，但能更真实地模拟实盘环境。

建议五：增加因子有效性的统计检验（IC分析和分层回测）。在将因子输入模型之前，应先检验每个因子的预测能力。信息系数（IC）分析可以量化因子值与未来收益的秩相关性，IC绝对值大于0.03的因子才具有实用价值。分层回测则将股票按因子值分为5或10档，检验高因子值组合是否系统性优于低因子值组合。对于IC趋近于零的因子，应予以剔除以减少噪声干扰。该步骤相当于“特征选择”，对模型最终性能的影响可能超过模型本身的选择。

建议六：在低信噪比金融数据中优先使用简单模型，并加强正则化。金融市场的低信噪比特性使得复杂模型更容易过拟合到噪声。建议优先使用L1/L2正则化的逻辑回归或浅层决策树（max_depth不超过5），并通过交叉验证选择正则化强度。对于随机森林等集成方法，应限制每棵树的深度和叶子节点最小样本数（如min_samples_leaf不小于20），防止模型记住训练数据中的噪声。TASK6的实验已证明决策树在金融数据上的表现优于随机森林——这与“模型简单性原则”高度一致。

建议七：探索深度学习与因子投资的融合。LSTM（长短期记忆网络）能够捕捉价格序列中的时序依赖关系，适合预测中短期价格趋势。Transformer架构的多头注意力机制可以自动学习不同因子之间的交互效应。建议从简单的LSTM价格预测模型入手，逐步引入多因子特征，最终构建多任务学习框架（同时预测价格方向和收益幅度）。但需特别注意深度学习模型的过拟合风险——深度模型的参数规模往往是金融样本量的数十倍。建议使用Dropout（0.3-0.5）、Early Stopping（验证集连续10个epoch无改善则停止）、数据增强（添加微小噪声、随机mask部分特征）等正则化手段，并在独立的时间窗口进行最终验证。